



TP-Projet 3 : Application de l'ACP : les «Eigenfaces»

Ce projet s'inspire d'un article intitulé *Eigenfaces for recognition*, écrit par Turk et Pentland et publié dans le *Journal of Cognitive Neuroscience* en 1991.

Description des données

Vous disposez de n images de visages d'un ensemble d'individus. Chaque individu est photographié sous le même nombre de postures faciales (gauche, face, trois quart face, etc.). Chacune de ces n images en niveaux de gris est stockée dans une matrice bidimensionnelle de taille 480×640 . Ces n images constituent les *images d'apprentissage*. En les vectorisant, vous pouvez donc représenter ces images par des vecteurs colonnes de \mathbb{R}^p , où $p = 480 \times 640 = 307200$ est le nombre de pixels commun à toutes les images. Alors que dans le TP1, chaque pixel d'une image couleur constitue un point de \mathbb{R}^3 , ici c'est chaque image qui constitue un point d'un espace affine \mathbb{R}^p de dimension très élevée.




FIGURE 1 – Une base de visages

Exercice 1 : analyse en composantes principales

La matrice des données X , de taille $n \times p$, contient sur chaque ligne la transposée d'une image vectorisée. Lancez le script `donnees.m` afin de créer cette matrice et de la stocker dans un fichier au format Matlab, de nom `donnees.mat`.

Attention, pour le TP, seuls 4 individus sur 37 et 4 postures sur 6 sont sélectionnées pour faire partie de la base d'apprentissage ; il faudra bien entendu considérer un plus grande nombre d'individus et de postures pour les tests de performance

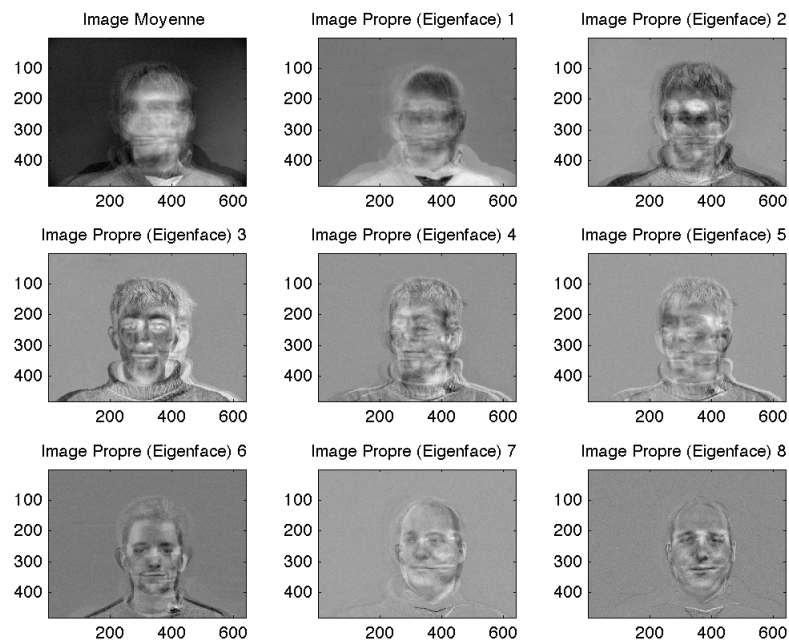


FIGURE 2 – Les «eigenfaces»

Complétez le script `exercice_1.m`, qui vise à calculer les axes principaux des images d'apprentissage à partir des vecteurs propres associés aux $n - 1$ valeurs propres non nulles de la matrice de variance/covariance Σ des données¹. Ces axes principaux sont appelés *eigenfaces* par Turk et Pentland, par contraction des mots anglais *eigenvectors* et *faces*.

1. comme ici on vous demande de calculer toutes les valeurs propres de la matrice (sauf une), le choix d'utiliser la fonction `eig` va de soi

Exercice 2 : projection des images sur les *eigenfaces*

Une fois connues les $n - 1$ *eigenfaces*, on peut calculer les composantes principales. Complétez le script `exercice_2.m`, de manière à afficher les images d'apprentissage reconstruites à l'aide des q premières *eigenfaces* et des q premières composantes principales, pour $q \in [0, n - 1]$.

Attention : n'oubliez pas d'ajouter l'individu moyen.

Ce script doit également afficher l'évolution, en fonction de q , de la racine carrée de l'erreur quadratique moyenne (*Root Mean Square Error*, ou RMSE) entre les images originales et les images ainsi reconstruites.

Exercice 3 : application à la reconnaissance de visages

Le script `clusters.m` calcule les composantes principales des n images d'apprentissage, puis affiche sous la forme d'un nuage de n points de \mathbb{R}^2 leurs deux premières composantes principales. Chaque couleur correspond à un même individu de la *base d'apprentissage*. Ce nuage fait apparaître des groupes de points (ou *clusters*) de couleur uniforme, ce qui montre que chaque *cluster* correspond aux différentes postures d'un même individu. Il semble donc possible d'utiliser les *eigenfaces* pour la reconnaissance de visages (comme l'indique le titre de l'article ayant inspiré ce TP : *Eigenfaces for recognition*), en calculant les deux premières composantes principales d'une image, dite *image de test*, n'appartenant pas forcément à la base d'apprentissage, et en cherchant de quelle image d'apprentissage cette image est la plus proche, donc à quel individu elle correspond.

$$\mathbf{x} \in \mathbb{R}^{307200} \rightarrow \boxed{\text{Projection Base ACP}} \rightarrow \phi(\mathbf{x}) \in \mathbb{R}^{q \ll 307200} \rightarrow \boxed{\text{Prédicteur } h} \rightarrow h(\mathbf{x})$$

Le script `exercice_3.m` tire aléatoirement (à l'aide de la fonction `randi` de Matlab) une image de test, parmi les 37 personnes et les six postures faciales disponibles dans la base de données.




FIGURE 3 – Résultat d'une requête sur une base de visages.

Travail en séance

Question 1 : `exercice_1.m` complété

Question 2 : `exercice_2.m` complété

Question 3 : `exercice_3.m` complété

Questions sur la reconnaissance de visages

1. Evaluation de la reconnaissance :

- **Question 4 :** Configurez un classifieur (type de classifieur 1ppv, 3ppv ou autre, ... vu en cours) en complétant le script `exercice_3.m`.
Le classifieur k-ppv a été vu au TP4 d'Analyse de Données.
- **Question 5 :** A partir des résultats obtenus de votre classifieur et des labels des images tests, construisez la matrice de confusion afin d'évaluer la qualité de votre classifieur. Comment optimiser votre classifieur ?
(on pourra notamment regarder le choix du nombre de composantes principales)

N'oubliez pas que vous avez à disposition 37 individus et 6 postures

2. Discussion :

- **Question 6 :** Compte tenu de la quantité de données fournie (nombre et taille des images), quelle est votre préconisation (algorithmique et informatique) pour le calcul des couples propres utiles à cette application ?
- **Question 7 :** Faut-il utiliser l'implantation cholesky (via `eig`) ou les algorithmes "subspace iteration" ?
(vous pouvez éprouver votre implantation Matlab de ces algorithmes dans ce cadre)²

3. Question 8 supplémentaire :

En travaillant sur tout ou partie de la Base d'Apprentissage, discutez de la pertinence (spectrale) de l'introduction de la couleur dans la reconnaissance des visages.

Lancez le script `donneesCouleur.m` afin de créer cette matrice et de la stocker dans un fichier au format Matlab, de nom `donneesCouleur.mat`.

2. Cette année, vu les conditions et l'obligation du travail à distance, nous avons enlevé l'interfaçage Matlab-Fortran qui permettait d'appeler le code Fortran des approches "subspace iteration" à partir du Matlab.

Annexe : Différences importantes avec le TP1 d'analyse de données

- Dans le TP1, la matrice des données centrées X_c est de taille $p \times 3$, où p désigne le nombre de pixels de l'image RVB. Or, le rang d'une matrice est inférieur à sa plus petite dimension. Comme $p \gg 3$, cela signifie que $\text{rg}(X_c) \leq 3$. Pour une image naturelle, le coefficient de corrélation linéaire entre les 3 canaux RVB n'est jamais exactement égal à ± 1 . Cela signifie que les 3 colonnes de X_c sont linéairement indépendantes, donc que $\text{rg}(X_c) = 3$ (on dit que X_c est *de rang maximal*). Une conséquence de ce résultat est que la matrice de variance/covariance $\Sigma = X_c^\top X_c / p$ est également de rang 3. Comme elle est de taille 3×3 , cette matrice est inversible.
- Dans ce TP, la matrice X_c des données centrées, obtenue en retranchant à chaque ligne de X l'*individu moyen* \bar{X} (égal à la moyenne des lignes de X), est de taille $n \times p$, où n désigne le nombre d'images et p le nombre de pixels commun à toutes ces images. Comme $p \gg n$, on en déduit que $\text{rg}(X_c) \leq n$. Pour que cette matrice soit de rang maximal, il faudrait que ses n lignes soient linéairement indépendantes. Or, leur somme est égale au vecteur nul, puisque \bar{X} est égal à la moyenne des n lignes de X . Pour des images naturelles, on en déduit que $\text{rg}(X_c) = n - 1$. La matrice de variance/covariance $\Sigma = X_c^\top X_c / n$ est donc elle aussi de rang $n - 1$. Comme elle est de taille $p \times p$, et que $p \gg n$, cette matrice n'est pas inversible. En l'occurrence, le noyau de Σ est de dimension $p - n + 1$.
- Une autre différence avec le TP1 vient de ce que, dans ce TP, la fonction `eig` ne peut pas être directement appliquée à Σ . En effet, sa taille $p \times p$ est gigantesque ($p = 307200$). Or, pour une matrice M quelconque, $M^\top M$ et $M M^\top$ ont les mêmes valeurs propres *non nulles*. On peut donc appliquer la fonction `eig` à $\Sigma_2 = X_c X_c^\top / n$, de taille $n \times n$ beaucoup plus petite, pour calculer les valeurs propres non nulles de Σ .
- Si Y est un vecteur propre de Σ_2 associé à une des $n - 1$ valeurs propres λ non nulles, alors par définition $(X_c X_c^\top / n) Y = \lambda Y$, d'où $(X_c^\top X_c / n) X_c^\top Y = \lambda X_c^\top Y$. D'autre part, $X_c^\top Y$ est un vecteur non nul : sinon, cela impliquerait que le vecteur λY est nul, ce qui est impossible puisque $\lambda \neq 0$ par hypothèse et que, étant un vecteur propre, Y ne peut pas être un vecteur nul. Par conséquent, $X_c^\top Y$ est un vecteur propre de $\Sigma = X_c^\top X_c / n$ associé à la valeur propre λ . Il est facile de montrer que les $n - 1$ vecteurs $X_c^\top Y$ sont orthogonaux deux à deux. En les normalisant, on obtient donc une base orthonormée \mathcal{B} de $\text{Im}(\Sigma)$.